

Web Scrapping Meets Travel.

By Aliaksandra Labko, Cezary Kuzmowicz



Outline

- 1. Introduction**
- 2. Tools**
- 3. Process**
- 4. Results & Conclusions**

Introduction.



gov.pl

Serwis Rzeczypospolitej Polskiej

Strona główna

Rada Ministrów

Kancelaria Premiera

Ministerstwa

Urzędy, instytucje
i placówki RP

 Usługi dla obywatela

 Usługi dla przedsiębiorcy

 Usługi dla urzędnika

 Usługi dla rolnika

Profil zaufany

Baza wiedzy

Serwis Służby Cywilnej

 Сайт для громадян України

–Serwis dla obywateli Ukrainy

Strona informacyjna - Pomoc dla powodzian

Urzędy, instytucje i placówki RP

Znajdź urząd, instytucje lub jednostkę administracji publicznej



Podpowiedzi

[Ministerstwa](#) [Urzędy centralne](#) [Urzędy wojewódzkie](#) [Stacje sanitarno-epidemiologiczne](#)

[Placówki zagraniczne RP](#) [Prokuratury](#) [Państwowa Straż Pożarna](#) [Szpitale](#)

[Polska w Albanii](#)

[Polska w Algierii](#)

[Polska w Angoli](#)

[Polska w Arabii Saudyjskiej](#)

[Polska w Argentynie](#)


[Polska w Armenii](#)

Legal Constrains

- **Robots.txt**
- **Terms of Service**




```
User-Agent: *  
Allow: /
```



There is no Terms of Service for <https://www.gov.pl/web/gov/katalog-jednostek>

Used Tools.

We used



Process.

Collecting Embassy Links with BS



Output is URLs like: gov.pl/albania, gov.pl/usa

We put our focus on...



**gov.pl**

Serwis Rzeczypospolitej Polskiej

 Szukaj usługi, informacji

SZUKAJ

 Zaloguj

Strona informacyjna - Pomoc dla powodźian [PRZEJDŹ DO STRONY](#)

Polska w Albanii [Ambasada](#) [Relacje dwustronne](#) [Informacje konsularne](#) [Aktualności](#) [PL](#)

POLAND25.EU **POLSKA PREZYDENCJA W RADZIE UNII EUROPEJSKIEJ** 

WYBORY PREZYDENTA RP 2025 ZA GRANICĄ 

Na skróty

Kontakt

Umawianie wizyt

Informacje dla podróżujących

Informator ekonomiczny

Aplikacja mobilna TVP Polonia



Aktualności
zobacz wszystkie

04.04.2025

Forum "Polish Presidency of the EU"

Scrapping Contact Info



Polska w Albanii

AmbasadaRelacje dwustronneInformacje konsularneAktualnościPL ▼

[Polska w Albanii](#) > [Ambasada](#) > [Ambasada](#)

Ambasada
Kierownik Placówki
Personel
Skargi i wnioski
Deklaracja dostępności
Zamówienia Publiczne

Ambasada

Ambasada RP w Tiranie
adres: [Rruga e Bogdanëve 50; 1001 Tirana](#)
telefon: [+355 445 100 20](#)
e-mail: tirana.amb.sekretariat@msz.gov.pl

Wydział Konsularny Ambasady RP w Tiranie

adres: [Rruga e Bogdanëve 50; 1001 Tirana](#)
telefon: [+355 445 100 20](#)
e-mail: tirana.wk.dyzurny@msz.gov.pl
godziny przyjęć: wtorki, czwartki 10:00 -12:00
Wizyty w konsulacie po uprzedniej rejestracji na stronie [e-konsulat](#).

Example output:

Rruga e Bogdanëve 50, Tirana | +355 445 100 20 | tirana.amb.sekretariat@msz.gov.pl

Scrapping Travel Rules



gov.pl Serwis Rzeczypospolitej Polskiej

Szukaj usługi, i

Strona główna
Rada Ministrów
Kancelaria Premiera
Ministerstwa
Urzędy, instytucje i placówki RP

Usługi dla obywatela
Usługi dla przedsiębiorcy
Usługi dla urzędnika
Usługi dla rolnika

Profil zaufany
Baza wiedzy

drogach lub w porze nocnej jest wysokie. Należy także unikać postoju w miejscach do tego nieprzeznaczonych i niestrzeżonych. Zaleca się zachowanie ostrożności, gdy ktoś nieznajomy proponuje pomoc lub podwiezienie. Należy korzystać wyłącznie z taksówek zrzeszonych w korporacjach.

Wjazd i pobyt

1. Na jakim dokumencie podróży można przekroczyć granicę?

- Paszport TAK
- Paszport tymczasowy TAK
- Dowód osobisty NIE

2. Jaka jest wymagana minimalna ważność dokumentu podróży?

6 MIESIĘCY

3. Czy trzeba wyrobić wizę?

Nie ma wymogu posiadania wiz, o ile pobyt nie przekracza 90 dni w okresie 180 dni.

W przypadku konieczności przedłużania pobytu w Brazylii skontaktuj się przed upływem 90 dni z Policją Federalną w miejscu swojego pobytu.

Example output:

<https://www.gov.pl/albania/informacje-dla-podr...> | Paszport TAK | Paszport tymczasowy TAK | Dowód osobisty TAK

Clean and Merge


Country	Passport	Temporary Passport	ID card	Polish embassy address	Phone Number	E-mail
Dania	TAK	TAK	TAK	Richelieus Allé 12, 2900 Hellerup	+45 39 46 77 00	copenhagen.info@msz.gov.pl
Egipt	TAK	TAK	NIE	5 El-Aziz Osman, Zamalek, Egipt, Kair	+20 227355416	cairo.secretariat@msz.gov.pl
Estonia	TAK	TAK	TAK	Suur-Karja 1/ Vana Turg 2, 10140 Tallinn	+3726278206	eetalamb@msz.gov.pl
Etiopia	TAK	TAK	NIE	Dej. Belay Zeleke Road, Gulele sub- City, Kebel...	+251 11 157 41 89	addisabeba.amb.sekretariat@msz.gov.pl
Filipiny	TAK	TAK	NIE	9th Floor, DelRosarioLaw Centre, 21st Drive co...	+63 2 53182700	manila.amb.sekretariat@msz.gov.pl
Finlandia	TAK	TAK	TAK	Armas Lindgrenin tie 21, 00570 Helsinki	+358 9 618 28 120	helsinki.amb.info@msz.gov.pl




Results & Conclusions.

×

×




final result is clean and user-friendly **DataFrame**



code scraps data for **50** countries



running time is **16** minutes



main challenges:

- HUGE website structure **variability** and text **mistakes**
- anti-scraping defenses resulting in **blockage**

```
ing simple DataFrame
travel_info = pd.DataFrame(result_data)
travel_info

843 new_e = ProtocolError("Connection aborted")
--> 845 retries = retries.increment(
846     method, url, error=new_e, _pool=self, _stack
847 )
848 retries.sleep()
850 # Keep track of the error for the retry warning.

File /opt/anaconda3/lib/python3.11/site-packages/urllib3/util
acktrace)
513 if new_retry.is_exhausted():
514     reason = error or ResponseError(cause)
--> 515     raise MaxRetryError(_pool, url, reason) from reason
517 log.debug("Incremented Retry for (url='%s'): %r", url
519 return new_retry

MaxRetryError: HTTPConnectionPool(host='localhost', port=533
(Caused by NewConnectionError('<urllib3.connection.HTTPConn
nnection refused'))
```

Wjazd i pobyt


1. Na jakim dokumencie podr

- paszport - TAK
- paszport tymczasowy - NIE
- dowód osobisty - NIE

Jaka jest wymagana minim

godnie z angielskimi przepi

mentu wjazdu, ale z





THANK YOU!

